

# تکلیف کامپیوتری سوم - درس شناسایی الگو

وحید ملکی  
شماره دانشجویی: ۴۰۳۱۳۰۰۴

۱۴۰۴ آذر ۱۶

## چکیده

در این تکلیف، هدف پیاده‌سازی و بررسی عملکرد الگوریتم EM (Expectation-Maximization) بر روی مدل ترکیبی گوسی (GMM) است. مسئله‌ی مورد مطالعه، Problem Annulus (مسئله‌ی حلقه) است که در آن نقاط داده‌ای به صورت یکنواخت در ناحیه‌ی بین دو دایره قرار دارند. با استفاده از GMM با  $C = 30$  مؤلفه‌ی گوسی و ماتریس‌های کوواریانس قطری، پارامترهای مدل تخمین زده و همگرایی مدل از طریق رسم کانتورهای بیضی در تکرارهای مختلف و بررسی نمودار Log-Likelihood تحلیل می‌شود.

# ۱ مقدمه و شرح مسئله

مسئله‌ی اصلی در این تمرین، یافتن توزیع احتمال (و پارامترهای آن) برای مجموعه‌ای از داده‌های دو بعدی است که از یک توزیع ساده‌ی نرمال تولید نشده‌اند، بلکه ساختاری پیچیده (شکل حلقوی) دارند. مدل ترکیبی گوسی (GMM Model Mixture Gaussian) یک راهکار قوی برای مدل‌سازی این گونه توزیع‌های پیچیده است.

## ۱۰۱ تولید مجموعه‌ی داده (Data Annulus)

مجموعه‌ی داده شامل  $N = 900$  نقطه دو بعدی است که به صورت یکنواخت در ناحیه‌ی بین دو دایره (حلقه) با شعاع داخلی  $r_{inner} = 1$  و شعاع خارجی  $r_{outer} = 2$  قرار دارند. برای تضمین یکنواختی نقاط در مساحت حلقه (ونه صرفاً در شعاع)، از روش تولید شعاع تصادفی با توزیع مناسب استفاده شده است. این روش شامل تولید  $r$  از توزیع یکنواخت برای مربع شعاع، یعنی  $Unifrom(r_{inner}^2, r_{outer}^2) \sim r^2$  است. زاویه‌ها نیز به صورت یکنواخت در بازه‌ی  $(0, 2\pi)$  تولید شده‌اند.

## ۲۰۱ تعریف مدل ترکیبی گوسی

مدل GMM با  $C = 30$  مؤلفه‌ی گوسی دو بعدی تعریف شده است. پارامترهای مدل شامل موارد زیر هستند:

- وزن‌های ترکیبی:  $\pi_k$ ، به طوری که  $\sum_{k=1}^C \pi_k = 1$ .
- میانگین‌ها:  $\mu_k \in \mathbb{R}^2$ .
- ماتریس‌های کوواریانس:  $\Sigma_k$  که ماتریس‌های قطری  $2 \times 2$  هستند.

## ۲ پیاده‌سازی الگوریتم EM و منطق حل

از آنجایی که برچسب هر نقطه (اینکه از کدام مؤلفه تولید شده) مجهول است (data Missing)، از الگوریتم تکراری EM (Expectation-Maximization) برای تخمین پارامترهای  $\theta = \{\pi_k, \mu_k, \Sigma_k\}_{k=1}^C$  استفاده می‌شود.

## ۱۰۲ مقداردهی اولیه (Initialization)

مقداردهی اولیه مطابق دستورالعمل تمرین انجام شده است:

- میانگین‌ها ( $\mu_k$ ): ۳۰ نقطه‌ی داده به صورت تصادفی از مجموعه‌ی  $X$  انتخاب شدند.
- وزن‌ها ( $\pi_k$ ): همگی به صورت مساوی  $\pi_k = 1/C = 1/30$  تنظیم شدند.
- کوواریانس‌ها ( $\Sigma_k$ ): ماتریس‌های قطری با واریانس نسبتاً بزرگ (براساس واریانس کل داده‌ها) مقداردهی شدند تا از بروز پدیده‌ی singularity جلوگیری شود.

## ۲۰۲ مراحل تکراری الگوریتم

الگوریتم EM در هر تکرار دو گام اصلی را اجرا می کند:

۱. گام امید (E-Step): در این گام، مسئولیت‌ها (Responsibilities) یا  $\gamma_{ik}$  محاسبه می‌شود. این مسئولیت نشان‌دهندهٔ احتمال تعلق نقطه‌ی  $x_i$  به مؤلفه‌ی گوسی  $k$ -ام، با توجه به پارامترهای فعلی است. ( $\theta^{\text{old}}$ )

$$\gamma_{ik} = P(z_i = k | x_i, \theta^{\text{old}}) = \frac{\pi_k \mathcal{N}(x_i | \mu_k, \Sigma_k)}{\sum_{j=1}^C \pi_j \mathcal{N}(x_i | \mu_j, \Sigma_j)}$$

۲. گام بیشینه‌سازی (M-Step): با استفاده از مسئولیت‌های  $\gamma_{ik}$  محاسبه شده در گام E، پارامترهای جدید ( $\theta^{\text{new}}$ ) به‌گونه‌ای محاسبه می‌شوند که امید ریاضی لگاریتم شباهت (که در E-Step محاسبه شده) بیشینه شود.

• تعداد مؤثر نقاط اختصاص داده شده به مؤلفه‌ی  $k$ :

$$\mu_k^{\text{new}} = \frac{1}{N_k} \sum_{i=1}^N \gamma_{ik} x_i$$

• بروزرسانی کوواریانس:

$$\Sigma_k^{\text{new}} = \frac{1}{N_k} \sum_{i=1}^N \gamma_{ik} (x_i - \mu_k^{\text{new}})(x_i - \mu_k^{\text{new}})^T$$


$$\pi_k^{\text{new}} = \frac{N_k}{N}$$

در پیاده‌سازی، برای  $\Sigma_k^{\text{new}}$  تنها عناصر روی قطر اصلی نگهداری شدن تا شرط ماتریس کوواریانس قطری حفظ شود.

## ۳ تحلیل خروجی‌ها

خروجی‌های کد پایتون شامل سه بخش اصلی زیر است:


### ۱۰۳ نمودار داده‌های تولید شده (Dataset Annulus Generated)



شکل ۱: نقاط داده‌ای Annulus تولید شده. یکنواختی سطحی حفظ شده و شعاع داخلی ۱ و خارجی ۲ به خوبی قابل مشاهده است.

تحلیل: همان‌طور که در شکل مشاهده می‌شود،  $N = 900$  نقطه به صورت یکنواخت در فضای حلقه‌ای بین  $r = 1$  و  $r = 2$  توزیع شده‌اند. این نشان می‌دهد که منطق تولید داده با استفاده از تبدیل تصادفی  $U \sim \sqrt{U}$  به درستی اعمال شده است.

## ۲۰۳ کانتورهای گوسی در تکرارهای مختلف




شکل ۲: بیضی‌های GMM در تکرارهای ۰ و 250 و 300. نقاط آبی داده‌ها و بیضی‌های قرمز، کانتور  $2\sigma$  هر مؤلفه گوسی را نشان می‌دهند.

**تحلیل همگرایی:**

- تکرار ۰ (Initialization): بیضی‌ها به صورت اولیه بزرگ و متتمرکز در نزدیکی مرکز هستند و تقریباً همه‌ی ناحیه‌ی داخلی را پوشش می‌دهند، که نتیجه‌ی مقداردهی اولیه با واریانس بزرگ است.
- تکرار 25 و 50 (Convergence Early): مؤلفه‌ها به سرعت از مرکز فاصله گرفته و شروع به قرارگیری در ناحیه‌ی متراکم داده‌ها (حلقه) می‌کنند. بیضی‌ها در این مرحله، داده‌ها را به صورت نودولار (گره‌ای) پوشش می‌دهند.
- تکرار 75 تا 300 (Convergence Final): با پیشرفت الگوریتم، 30 مؤلفه گوسی به صورت منظم در امتداد حلقه پخش می‌شوند و هر مؤلفه مسئول مدل‌سازی بخشی کوچک از اخنای حلقه است. در تکرارهای 275 و 300، تفاوت بسیار اندک است که نشان‌دهنده‌ی رسیدن مدل به یک بیشینه‌ی محلی از شباهت (Likelihood Local Maximum) است. این رفتار مطلوب و مطابق با انتظار مسئله است.

## ۳.۳ نمودار Log-Likelihood در مقابل تکرار



شکل ۳: نمودار Log-Likelihood در برابر تکرارها.

تحلیل:

- صعود مونوتون: همان‌طور که در شوری الگوریتم EM مورد انتظار است، مقدار Log-Likelihood در هر تکرار افزایش می‌یابد (صعودی یکنواخت یا Increase Monotonic).
- همگرایی: شب افزایش در تکرارهای اولیه (تا حدود تکرار 100) بسیار تند است و پس از آن کاهش می‌یابد. نمودار در حوالی تکرار 200 تا 250 عملاً اشباع (Saturation) شده و مقدار آن به نزدیکی مقدار نهایی ( $\approx 2005$ ) می‌رسد. این همگرایی قوی نشان‌دهنده‌ی موفقیت الگوریتم در تخمین پارامترها و رسیدن به بیشینه‌ی محلی شباهت است.