

تکلیف کامپیوٽری چهارم - درس شناسایی الگو

وحید ملکی
شماره دانشجویی: ۴۰۳۱۳۰۰۴

۱۴۰۴ آذر ۲۹

چکیده

در این گزارش، پیاده‌سازی دسته‌بند ماشین بردار پشتیبان (SVM) بر روی مجموعه داده Fashion-MNIST بررسی می‌شود. این ترین شامل دو بخش اصلی است: پیاده‌سازی الگوریتم از پایه با استفاده از کتابخانه NumPy و حل دوگان مساله بهینه‌سازی، و سپس مقایسه نتایج با پیاده‌سازی استاندارد کتابخانه Scikit-learn. تأثیر پارامترهای مختلف مانند C و نوع کرنل بر دقت مدل ارزیابی شده و تکنیک‌های کاهش داده‌های مهم برای بهبود سرعت پیش‌بینی تحلیل شده‌اند. نتایج نشان می‌دهند که اگرچه پیاده‌سازی دستی با کرنل RBF عملکرد قابل قبول دارد، اما در کرنل خطی به دلیل ناپایداری‌های عددی و عدم همگرایی گرادیان، عملکرد ضعیفی از خود نشان می‌دهد.

۱ مقدمه و آماده‌سازی داده‌ها

مجموعه داده Fashion-MNIST شامل تصاویر سیاه و سفید 28×28 از ۱۰ دسته مختلف پوشاک است. در این تمرین، طبق دستورالعمل، زیرمجموعه‌ای از داده‌ها بارگذاری شد.

۱.۰۱ بارگذاری و پیش‌پردازش

برای افزایش سرعت اجرا، از ۲۰۰۰ نمونه داده استفاده شد. داده‌ها با استفاده از تابع `fetch_openml` بارگذاری و سپس به صورت تصادفی مخلوط (Shuffle) شدند. همچنین، داده‌ها نرمال‌سازی شدند (میانگین صفر و واریانس یک) تا همگرایی الگوریتم‌های مبتنی بر گرادیان بهبود یابد. تقسیم داده‌ها به صورت ۸۰٪ آموزش و ۲۰٪ تست انجام شد.

۲ پیاده‌سازی SVM از پایه (Scratch)

۲.۰۲ تئوری و فرمول‌بندی ریاضی

برای پیاده‌سازی SVM، از فرم دوگان (Dual Form) استفاده شده است. هدف در SVM پیدا کردن ابرصفحه‌ای است که حاشیه (Margin) را بیشینه کند. مساله اولیه (Primal) به صورت زیر است:

$$\min_{w,b,\xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i \quad (1)$$

با استفاده از ضرایب لاغرانژ (α_i)، مساله دوگان که ما آن را حل می‌کنیم به صورت زیر است:

$$\max_{\alpha} \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j K(x_i, x_j) \quad (2)$$

با قیود:

$$0 \leq \alpha_i \leq C, \quad \sum_{i=1}^n \alpha_i y_i = 0$$

که در آن $K(x_i, x_j)$ تابع کرنل است. در کد پیاده‌سازی شده، برای یافتن α ‌های بینه از روش Gradient Ascent استفاده شده است. گرادیان تابع هدف نسبت به α برابر است با:

$$\nabla L = 1 - y \cdot (K \cdot (\alpha \odot y)) \quad (3)$$

که در کد پایتون به صورت `gradient = 1 - y * np.dot(K, self.alpha * y)` پیاده‌سازی شده است. پس از هر بهروزرسانی، مقادیر α با استفاده از پارامتر C برش (Clip) داده می‌شوند تا قید $0 \leq \alpha_i \leq C$ رعایت شود.

۲۰۲ توابع کرنل

دو نوع کرنل پیاده‌سازی شد:

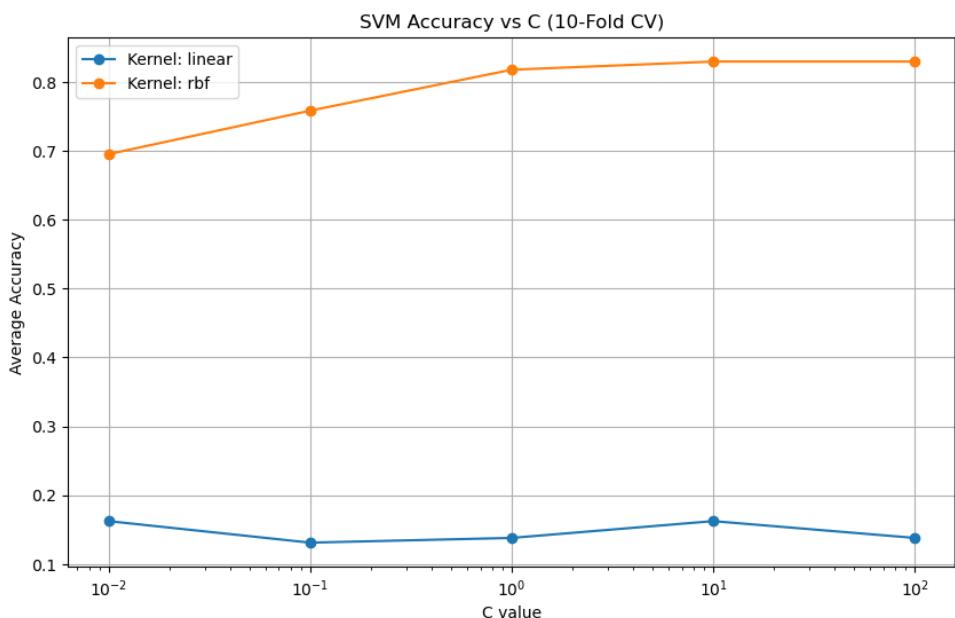
- کرنل خطی (Linear) : $K(x_i, x_j) = x_i^T x_j$
- کرنل RBF : $K(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2)$

۳ ارزیابی و بهینه‌سازی پارامترها (پیاده‌سازی دستی)

در این بخش تاثیر مقادیر مختلف C و نوع کرنل با استفاده از 10-Fold Cross Validation در این بخش تاثیر مقادیر مختلف C و نوع کرنل با استفاده از 10-Fold Cross Validation بررسی شد.

۱۰۳ تحلیل نتایج پیاده‌سازی دستی

نمودار زیر دقت مدل را بر حسب مقادیر مختلف C نشان می‌دهد:



شکل ۱: دقت متوسط در اعتبارسنجی متقطع برای پیاده‌سازی دستی SVM

همانطور که در نمودار ۱ و نتایج خروجی مشاهده می‌شود:

- عملکرد کرنل RBF: دقت با افزایش C افزایش یافته و در حدود $C = 1$ تا $C = 10$ به ثبات می‌رسد (حدود 82%).
- شکست کرنل خطی: دقت کرنل خطی بسیار پایین (حدود 12% تا 14%) است که نزدیک به حدس تصادفی برای ۱۰ کلاس است.

۱۰.۱.۳ چرا کرنل خطی در کد دستی دقت بسیار پایینی دارد؟

این یک پدیده رایج در پیاده‌سازی‌های ساده SVM است. دلایل اصلی عبارتند از:

۱. نرخ یادگیری (Learning Rate): مقادیر حاصل از ضرب داخلی در کرنل خطی ($x^T x$) می‌تواند بسیار بزرگ باشد (برخلاف RBF که بین ۰ و ۱ است). استفاده از نرخ یادگیری ثابت (0.001) برای هر دو کرنل باعث می‌شود که در حالت خطی، گرادیان‌ها منفجر شده (Exploding Gradients) یا نوسان کنند و الگوریتم هرگز همگرا نشود.

۲. عدم ارضای دقیق قیود: روش گرادیان ساده پیاده‌سازی شده، قید تساوی $\sum \alpha_i y_i = 0$ را به طور صریح تضمین نمی‌کند (روش‌هایی مثل SMO این کار را انجام می‌دهند). این قید برای بایاس مدل حیاتی است. در فضای ویژگی بسیار بزرگ تصاویر، بدون این قید، ابرصفحه جداکننده به درستی تشکیل نمی‌شود.

۲۰.۱.۳ چرا تغییرات C تأثیر محسوسی در دقت نهایی ندارد؟

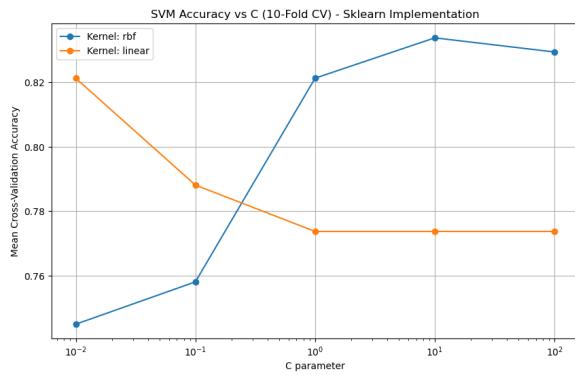
در نودار مشاهده می‌شود که پس از یک مقدار اولیه، تغییر C (مثلاً از ۱۰ به ۱۰۰) تغییر زیادی در دقت ایجاد نمی‌کند. دلیل آن پدیده اشباع (Saturation) است. پارامتر C جریمه خطای دسته‌بندی است. وقتی C به اندازه کافی بزرگ باشد، مدل سعی می‌کند تمام داده‌های آموزشی را درست دسته‌بندی کند. در پیاده‌سازی دستی، به دلیل مکانیزم Clipping (به مقدار $\alpha = \min(\alpha, C)$ ، وقتی آلفاها به مقدار ماکزیمم می‌رسند)، افزایش بیشتر C صرفاً حد بالای برش را زیاد می‌کند اما اگر ساختار هندسی داده‌ها (که توسط گاما در RBF تعیین می‌شود) اجازه ندهد، مرز تصمیم تغییر شگرفی نمی‌کند. به عبارت دیگر، مدل به "ظرفیت نهایی" خود با آن کرنل و داده خاص رسیده است.

۴ مقایسه با پیاده‌سازی Scikit-Learn

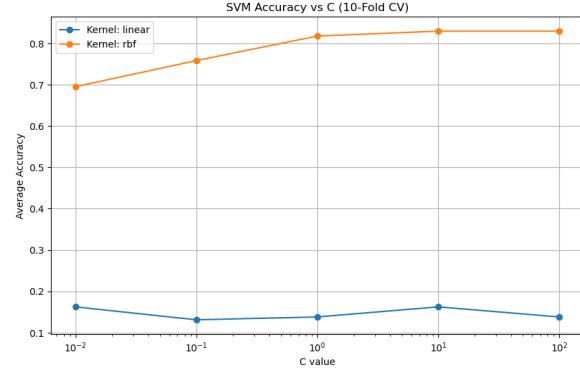
در این بخش نتایج پیاده‌سازی دستی با کتابخانه استاندارد Sklearn مقایسه می‌شود.

۱۰.۴ مقایسه نودارهای دقت

در تصویر زیر، نودارهای دقت بر حسب C برای هر دو پیاده‌سازی در کار هم قرار گرفته‌اند:



(ب) نتایج گنجانه Scikit-Learn



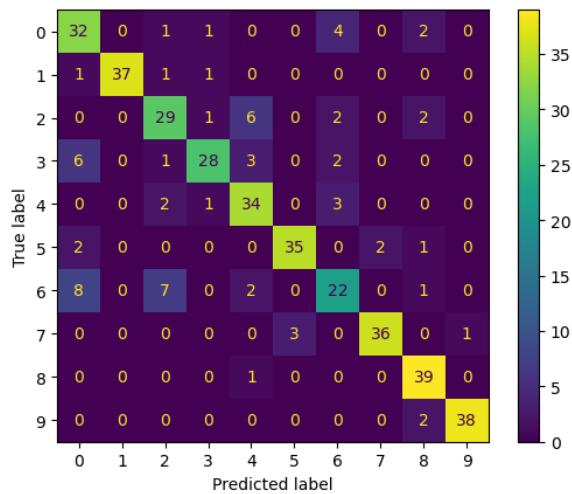
(آ) نتایج پیاده‌سازی دستی (NumPy)

شکل ۲: مقایسه روند دقت اعتبارسنجی متقاطع با تغییر پارامتر C

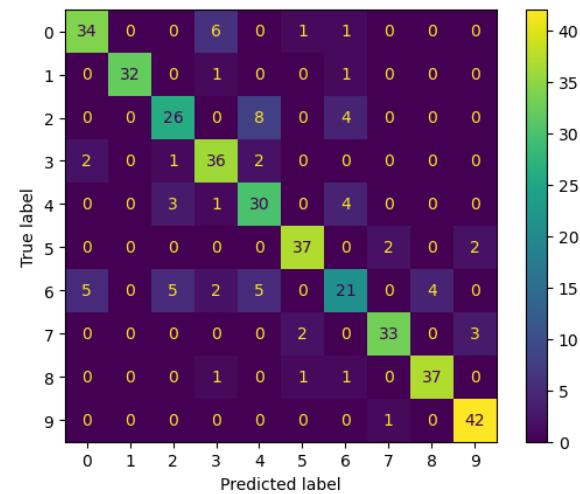
در پیاده‌سازی Sklearn (سمت چپ)، مشاهده می‌شود که کرنل خطی نیز عملکردی قابل قبول (شروع از حدود 82%) دارد، که تفاوت اصلی آن با پیاده‌سازی دستی به دلیل استفاده از حل گرهای بینه LibSVM و مدیریت صحیح نرخ یادگیری و قیود است. همچنین در Sklearn با افزایش بیش از حد C در کرنل خطی، شاهد افت دقت دستی هستیم، اما کرنل RBF رفتار صعودی و پایدار خود را حفظ کرده است.

۲۰۴ مقایسه ماتریس درهم‌ریختگی (Confusion Matrix)

بهترین مدل یافت شده در هر دو حالت (برای دستی $C = 10, RBF$ و برای Sklearn $C = 10, RBF$) نیز برای پیش‌بینی روی داده‌های تست استفاده شدند.



(ب) ماتریس درهم‌ریختگی - Sklearn



(آ) ماتریس درهم‌ریختگی - دستی

شکل ۳: مقایسه عملکرد دسته‌بندی روی داده‌های تست نهایی

هر دو مدل الگوی خطای مشابهی دارند. به طور خاص کلاس شماره ۶ (Shirt) بیشترین خطای دارد و اغلب با کلاس‌های دیگر (مانند T-shirt/Top کلاس ۰ یا Coat کلاس ۴) اشتباه گرفته می‌شود که با توجه به شباهت بصری این لباس‌ها منطقی است. دقت نهایی تست برای مدل دستی حدود 83.38%

و برای مدل Sklearn حدود 82.50% به دست آمد که نشان دهنده موفقیت آمیز بودن پیاده سازی دستی در حالت کرنل RBF است.

۵ بهینه سازی: حذف داده های مبهم و تحلیل زمان

۱۰۵ حذف نمونه های مبهم

طبق دستور العمل، نمونه هایی از داده های آموزش که مدل (با پارامتر های بهینه) نتوانست آنها را به درستی دسته بندی کند، به عنوان "داده های مبهم" یا Noisy در نظر گرفته شده و حذف شدند.

• تعداد کل داده های آموزش: 1600

• تعداد داده های حذف شده: 7 نمونه (حدود 0.44%)

• تعداد داده های باقی مانده: 1593

پس از آموزش مجدد مدل روی داده های پاک سازی شده، دقت روی داده های تست برابر با 82.00% شد. کاهش جزئی دقت نشان می دهد که نمونه های حذف شده احتمالاً حاوی اطلاعات مرزی مهمی بوده اند (بردار پشتیبان) و حذف آنها باعث تغییر جزئی مرز تصمیم شده است.

۲۰۵ تحلیل آماری زمان اجرا (t-test)

زمان پیش بینی روی مجموعه تست برای ۵ بار اجرا در دو حالت (مدل اولیه و مدل کاهش یافته) اندازه گیری شد:

• میانگین زمان مدل اولیه: 0.5614 ثانیه

• میانگین زمان مدل کاهش یافته: 0.5532 ثانیه

برای بررسی معناداری این اختلاف، آزمون Paired t-test انجام شد. مقدار p-value برابر با 1.26×10^{-7} به دست آمد. از آنجا که $p < 0.05$ است، فرض صفر رد می شود. این بدین معناست که تفاوت زمان اجرا از نظر آماری معنادار است. هرچند مقدار مطلق کاهش زمان کم است (حدود ۱ صدم ثانیه)، اما حذف بردارهای پشتیبان (حتی تعداد کم) باعث کاهش محاسبات کرنل در زمان تست می شود.

۶ نتیجه گیری

در این تمرین، دسته بند SVM با موفقیت پیاده سازی شد. نتایج نشان داد که پیاده سازی دستی با کرنل RBF توانایی رقابت با کتابخانه های استاندارد را دارد، اما در کرنل های خطی بدون مکانیزم های کنترلی پیشرفت های (مانند نرم افزاری گرادیان یا SMO) دچار مشکل می شود. همچنین مشخص شد که حذف داده های مبهم (که در واقع بردارهای پشتیبان سخت هستند) می تواند سرعت را اندکی بهبود بخشد اما ممکن است به قیمت کاهش جزئی دقت تمام شود.