

تکلیف کامپیوتری چهارم - درس شناسایی الگو

وحید ملکی
شماره دانشجویی: ۴۰۳۱۳۰۰۴

۱۴۰۴ آذر ۲۵

۱ مقدمه و آماده‌سازی داده‌ها

در این تکلیف، هدف پیاده‌سازی و ارزیابی ماشین بردار پشتیبان (SVM) بر روی مجموعه داده Fashion-MNIST است. این مجموعه داده شامل تصاویر 28×28 پیکسلی از پوشاک در 10 کلاس مختلف است. به دلیل حجم بالای داده‌ها و محدودیت‌های محاسباتی در پیاده‌سازی دستی، از یک زیرمجموعه شامل 2000 نمونه استفاده شد. ابتدا داده‌ها بارگذاری شده و به طور تصادفی مخلوط (Shuffle) شدند. سپس 20 درصد از داده‌ها (معادل 400 نمونه) به عنوان داده‌های آزمون (Test Set) و 80 درصد باقی‌مانده (معادل 1600 نمونه) به عنوان داده‌های آموزش (Train Set) جدا شدند. برای بهبود عملکرد الگوریتم‌های مبتنی بر گرادیان، داده‌ها نرمال‌سازی شدند تا میانگین صفر و واریانس یک داشته باشند.

۲ پیاده‌سازی مدل SVM با استفاده از NumPy

در بخش اول، الگوریتم SVM بدون استفاده از کتابخانه‌های آماده و صرفاً با استفاده از جبر خطی در NumPy پیاده‌سازی شد.

۱۰۲ ریاضیات و منطق کلاس SVMScratch

این کلاس هسته اصلی الگوریتم را تشکیل می‌دهد و برای حل مسئله بهینه‌سازی SVM از روش «گرادیان صعودی» (Gradient Ascent) بر روی فرم دوگان (Dual Form) استفاده می‌کند.

۱۰۱۰۲ تابع kernel

این تابع وظیفه محاسبه ماتریس کرنل (شباخت بین نمونه‌ها) را بر عهده دارد. دو نوع کرنل پیاده‌سازی شد:

- کرنل خطی (Linear): به صورت ضرب داخلی دو بردار ویژگی تعریف می‌شود:

$$K(x_i, x_j) = x_i^T x_j \quad (1)$$

- کرنل RBF: که بر اساس فاصله اقلیدسی عمل می‌کند و قابلیت جداسازی غیرخطی را فراهم می‌آورد:

$$K(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2) \quad (2)$$

۲۰۱۰۲ تابع fit

این تابع ضرایب لاگرانژ (α) را یاد می‌گیرد. هدف ما بیشینه‌سازی تابع هدف دوگان است:

$$L(\alpha) = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j K(x_i, x_j) \quad (3)$$

مشتق این تابع نسبت به α برابر است با:

$$\nabla L = 1 - y_i \sum_{j=1}^n \alpha_j y_j K(x_i, x_j) \quad (4)$$

در حلقه یادگیری، مقادیر α با نرخ یادگیری (lr) در جهت گرادیان بهروزرسانی می‌شوند. همچنین شرط محدودیت جعبه‌ای ($0 \leq \alpha \leq C$) با استفاده از تابع clip اعمال می‌شود. در نهایت، مقدار بایاس (b) با استفاده از بردارهای پشتیبان (نقاطی که $0 < \alpha < C$) محاسبه می‌شود.

۳۰۱۰۲ تابع decision_function

برای پیش‌بینی امتیاز یک نمونه جدید x ، از رابطه زیر استفاده می‌شود:

$$f(x) = \sum_{i \in SV} \alpha_i y_i K(x_i, x) + b \quad (5)$$

این مقدار نشان‌دهنده فاصله نمونه تا ابرصفحه جداکننده است.

۲۰۲ استراتژی چند کلاسه و ارزیابی

از آنجا که SVM ذاتاً یک طبقه‌بند بایزی است، برای مسئله ۱۰ کلاسه از استراتژی «یکی در برابر بقیه» (One-vs-Rest) در تابع train_svm استفاده شد. به ازای هر کلاس، یک مدل آموزش داده می‌شود که آن کلاس را +1 و سایرین را -1 در نظر می‌گیرد. تابع predict خروجی تمام ۱۰ مدل را دریافت کرده و کلاسی که بیشترین امتیاز (بیشترین فاصله مثبت از مرز تصمیم) را داشته باشد، به عنوان برچسب نهایی انتخاب می‌کند (argmax).

۳۰۲ اعتبارسنجی متقارن (Cross-Validation)

برای انتخاب بهترین فرآیندهای، از روش Fold Cross-Validation-10 استفاده شد. تابع get_k_folds داده‌های آموزش را به ۱۰ بخش مساوی تقسیم می‌کند. نتایج میانگین دقت برای مقادیر مختلف C و کرنل‌ها به شرح زیر به دست آمد:


- کرنل خطی (Linear): همان‌طور که مشاهده می‌شود، دقت در تمامی مقادیر C بسیار پایین (حدود ۱۶%) است.

%52.61 >= 1=C %57.41 >= 1.0=C %91.71 >= 10.0=C
%52.61 >= 001=C %65.61 >= 01=C

الگوریتم ماهیت دستی، پیاده‌سازی در ضعیف عملکرد این اصلی دلیل خطی: ضعیف عملکرد تحلیل کرنل خطای سطح بعد)، 784 (بالا ابعاد با ویژگی‌های فضای در است. ساده صعودی گرایان $\sum \alpha_i y_i = 0$) تساوی شرط دقیق اعمال بدون ساده گرایان الگوریتم و است نامهوار بسیار خطی و شود همگرا نمی‌تواند، SMO Coordinate Descent، یا مانند پیشرفت تر روش‌های از استفاده بدون و می‌شود. نوسان دچار

• **کرنل RBF:** عملکرد بسیار بهتری نشان داد و با افزایش C دقت بهبود یافت.

$\%36.18 >= 1=C$	$\%05.67 >= 1.0=C$	$\%60.17 >= 10.0=C$
$\%60.38 >= 001=C$	$\%60.38 >= 01=C$	



شکل ۱: نمودار تغییرات دقت بر حسب مقدار C در پیاده‌سازی دستی (NumPy)

٤٠٢ نتیجه نهایی مدل NumPy

بهترین پارامترهای یافته شده عبارتند از 'kernel='rbf' و $C = 10$ که دقت اعتبارسنجی 83.06% را داشت. پس از آموزش مجدد مدل با این پارامترها روی کل داده‌های آموزش، دقت نهایی روی داده‌های آزمون برابر با 81.61% به دست آمد.

٣ پیاده‌سازی با استفاده از Scikit-Learn


در این بخش از کتابخانه استاندارد sklearn برای پیاده‌سازی استفاده شد که از حل گر قدرتمند LibSVM استفاده می‌کند.

۱۰۳ اجزای استفاده شده

- **StandardScaler**: برای نرمال‌سازی داده‌ها (میانگین صفر و انحراف معیاریک) استفاده شد که تأثیر بسزایی در همگرایی SVM دارد.
- **OneVsRestClassifier**: این کلاس به صورت خودکار استراتژی یکی در برابر بقیه را برای مسائل چند کلاسه مدیریت می‌کند.
- **StratifiedKFold**: برخلاف تقسیم تصادفی ساده، این روش تضمین می‌کند که نسبت کلاس‌ها در هر Fold حفظ شود که برای داده‌های غیرمتوازن حیاتی است.
- **GridSearchCV**: جستجوی شبکه‌ای برای یافتن بهترین ترکیب فرآپارامترها (C و نوع کرنل) همراه با اعتبارسنجی مقاطعه.

۲۰۳ تحلیل نتایج Scikit-Learn

نتایج جستجوی شبکه‌ای نشان داد که پیاده‌سازی گابخانه‌ای رفتار پایدارتری دارد. نمودار دقت بر حسب پارامتر C در شکل زیر (در صورت فعل سازی) قابل مشاهده است. نکته قابل توجه این است که در پیاده‌سازی sklearn، کرنل خطی نیز عملکرد قابل قبول دارد، اما همچنان کرنل RBF برتری دارد.



شکل ۲: نمودار تغییرات دقت بر حسب مقدار C در پیاده‌سازی Scikit-Learn

بهترین مدل در این حالت نیز با پارامترهای $C = 10$ و کرنل RBF به دست آمد که دقت اعتبارسنجی آن ۸۳.۳۸% بود. دقت نهایی روی داده‌های آزمون برابر با ۸۲.۵۰% شد.

۴ مقایسه و نتیجه‌گیری

مقایسه نتایج نهایی نشان می‌دهد که پیاده‌سازی دستی ما با وجود سادگی، عملکرد بسیار نزدیکی به گابخانه بهینه شده Scikit-Learn دارد (۸۱.۶۱% در مقابل ۸۲.۵۰%).

۱۰۴ تحلیل گزارش کلاس‌بندی (Classification Report)

با مقایسه گزارش‌های کلاس‌بندی هر دو مدل، نتایج زیر حاصل می‌شود:

- کلاس‌های موفق: هر دو مدل در تشخیص کلاس ۱ (شلوار) و کلاس ۹ (کفش ساق‌دار) بسیار عالی عمل کرده‌اند (دقت بالای ۹۵٪). این نشان می‌دهد ویژگی‌های این کلاس‌ها تمایز بالایی دارند.
- کلاس‌های چالش برانگیز: کلاس ۶ (پیراهن) در هر دو مدل کمترین دقต را داشته است (Recall حدود ۰.۵۵). این کلاس به دلیل شباهت ظاهری زیاد به تی شرت (کلاس ۰) و پلوشرت (کلاس ۲)، بیشترین خطأ را ایجاد کرده است.
- پایداری: مدل Scikit-Learn در کلاس‌های دشوار کمی متعادل‌تر عمل کرده است، اما الگوی خطاهای در هر دو مدل یکسان است که نشان‌دهنده ماهیت داده‌هاست.

در جدول زیر گزارش نهایی مدل Scikit-Learn آورده شده است:

جدول ۱: گزارش کلاس‌بندی نهایی (بهترین مدل)

Class	Precision	Recall	F1-Score	Support
0	0.65	0.80	0.72	40
1	1.00	0.93	0.96	40
2	0.71	0.72	0.72	40
3	0.88	0.70	0.78	40
4	0.74	0.85	0.79	40
5	0.92	0.88	0.90	40
6	0.67	0.55	0.60	40
7	0.95	0.90	0.92	40
8	0.83	0.97	0.90	40
9	0.97	0.95	0.96	40
Accuracy			0.82	400