

حل تمرینات شناسایی الگو - سوال ۹

وحید ملکی

۲۲ آذر ۱۴۰۴

سوال ۹ - بخش الف: تاثیر پارامتر تنظیم C در SVM

در ماشین بردار پشتیبان (SVM)، پارامتر C نقش جریمه خطاها را بازی می کند و تعادلی میان «ماکزیم کردن حاشیه» (Margin) و «کمینه کردن خطای دسته بندی» ایجاد می کند.

۱. شکل سمت چپ ($C = 0.05$)

تحلیل: مقدار C بسیار کوچک است. این یعنی جریمه خطا کم است و مدل ترجیح می دهد حاشیه (Margin) را پهن تر نگه دارد، حتی اگر تعدادی از داده ها اشتباه دسته بندی شوند یا درون حاشیه قرار بگیرند (Soft Margin).
مرز تصمیم گیری: یک خط با جهت گیری کلی که سعی دارد توده اصلی داده ها را جدا کند، اما نسبت به داده های پرت (Outliers) حساسیت کمی دارد.
بردارهای پشتیبان (Support Vectors): در حالت حاشیه نرم، هر داده ای که:

۱. دقیقاً روی مرز حاشیه باشد،

۲. درون ناحیه حاشیه (بین دو خط چین فرضی) قرار داشته باشد،

۳. یا در سمت اشتباه دسته بندی شده باشد،

یک بردار پشتیبان است. بنابراین در شکل سمت چپ، تعداد بردارهای پشتیبان زیاد است (شامل داده های پرت دایره و ستاره و همچنین داده های نزدیک به خط مرزی).

۲. شکل سمت راست ($C = 10000$)

تحلیل: مقدار C بسیار بزرگ است. این یعنی جریمه خطا بسیار سنگین است و مدل تمام تلاش خود را می کند تا تمام داده ها را درست دسته بندی کند (رفتار شبیه به Hard Margin). مدل حاشیه را باریک می کند تا بتواند از بین داده های نزدیک به هم عبور کند.

مرز تصمیم گیری: خطی که سعی کرده خود را با داده های مرزی دقیقاً تنظیم کند تا خطایی رخ ندهد.

بردارهای پشتیبان: در این حالت حاشیه بسیار باریک است. تنها داده هایی که دقیقاً مماس بر حاشیه هستند (نزدیک ترین داده ها به خط جدا کننده) به عنوان بردار پشتیبان انتخاب می شوند. بنابراین در شکل سمت راست، تعداد بردارهای پشتیبان کم است (احتمالاً تنها ۱ یا ۲ داده از هر کلاس که کمترین فاصله را تا خط دارند).

سوال ۹ - بخش ب: نظیر کردن کرنل‌ها و شکل‌ها

در این بخش باید توصیف‌های (الف) تا (و) را به شکل‌های ۱ تا ۶ نظیر کنیم.

- (الف) دسته‌بند SVM خطی با حاشیه تمایز نرم و $C = 0.1$:
این گزینه متناظر با شکل ۳ است.
دلیل: مرز خطی است. چون C کوچک است، حاشیه (فاصله خط‌چین‌ها تا خط ممتد) پهن و عریض در نظر گرفته شده است و برخی داده‌ها به درون حاشیه نفوذ کرده‌اند.
 - (ب) دسته‌بند SVM خطی با حاشیه تمایز نرم و $C = 10$:
این گزینه متناظر با شکل ۴ است.
دلیل: مرز خطی است. چون C بزرگتر است، حاشیه باریک‌تر شده و سخت‌گیری بیشتری روی داده‌ها اعمال شده است (خط‌چین‌ها به خط ممتد نزدیک‌ترند).
 - (ج) دسته‌بند SVM غیرخطی با کرنل $K(u, v) = u^t v + (u^t v)^2$:
این گزینه متناظر با شکل ۱ است.
دلیل: این یک کرنل چندجمله‌ای درجه ۲ است. مرزهای تصمیم‌گیری حاصل از درجه ۲ می‌توانند مقاطع مخروطی (بیضی، دایره، سهمی و ...) باشند. شکل ۱ یک مرز بیضی‌شکل بسته را نشان می‌دهد که مشخصه بارز کرنل‌های درجه ۲ است.
 - (د) دسته‌بند SVM غیرخطی با کرنل گاوسی و $\gamma = 0.25$:
این گزینه متناظر با شکل ۵ است.
دلیل: فرمول کرنل گاوسی $\exp(-\gamma \|u - v\|^2)$ است. در اینجا $\gamma = 1/4 = 0.25$ مقدار کوچکی است. گامای کوچک باعث ایجاد واریانس بالا و مرزهای تصمیم‌گیری هموار و نرم (Smooth) می‌شود که کلیت داده‌ها را جدا می‌کند. شکل ۵ یک منحنی هموار است.
 - (ه) دسته‌بند SVM غیرخطی با کرنل گاوسی و $\gamma = 4$:
این گزینه متناظر با شکل ۶ است.
دلیل: در اینجا $\gamma = 4$ مقدار بزرگی است. گامای بزرگ باعث می‌شود مدل بسیار موضعی عمل کند و دور تک‌تک داده‌ها یا دسته‌های کوچک «جزیره» ایجاد کند. (Overfitting) شکل ۶ دقیقاً نشان‌دهنده این رفتار است که یک مرز بسته‌ی جزیره‌ای دور گروهی از داده‌ها تشکیل شده است.
- نکته: شکل ۲ در گزینه‌ها استفاده نشد (یا می‌تواند حالت دیگری از کرنل چندجمله‌ای باشد، اما شکل ۱ برای چندجمله‌ای و شکل ۵ و ۶ برای گاوسی گزینه‌های دقیق‌تری هستند).